

# Causal Bayesian Network

## I. Introduction

### 1. AI/ML/DL 엔지니어 & 리서처가 왜 인과관계에 대해서 고민해야 할까?

- Judea Pearl의 “Ladder of Causation”에 따르면, 인과관계 추론은 세 단계로 구성됨.
  - [1단계] Association
    - 서로 연관성이 높은 현상들을 찾고, 추세를 바탕으로 예측한다 (현재 대부분의 머신러닝 방식).
  - [2단계] Intervention
    - 어떤 행동을 취했을 때 무슨 일이 일어나는지 예측한다 (강화학습에서 많이 다루는 영역).
  - [3단계] Imagining
    - 발생하지 않은 상황을 상상한다(인과관계 추론의 최종 목표, Counterfactuals).
      - 인과관계 추론을 통해 Counterfactual를 더 잘 예상할 수 있게 된다면?
      - 현재의 AI가 한 단계 더 도약할 수 있을 것이다!

### 2. Causal Bayesian Network란 무엇일까?

- Causal model을 모델링 하기 위해서 bayesian network를 사용한다.
- 즉, Bayesian Network에 causal inference 개념을 넣은 게 Causal Bayesian Network.

## II. Causality & Causal Model

### 1. 상관관계(Correlation) vs. 인과관계(Causality)

- (예시) 매달 상어에게 습격당한 사람의 수와 해당 기간에 팔린 아이스크림의 수를 함께 모델링하는 경우:
  - 이 둘 사이에는 높은 상관관계(correlation)가 있음.
    - 이 상관관계(correlation)은 더위라는 covariable 때문으로, 더우면 바닷가를 찾는 사람이 많고, 동시에 아이스크림의 판매량 또한 증가하기에 존재하는 것.

- → 더워라는 변수를 그대로 둔 채 아이스크림의 판매를 규제해봐야, 상어에 습격당하는 사람의 수가 줄지는 않음.
- ⇒ 이처럼 상관관계(correlation)는 인과관계(causation)를 의미하지는 않음
- Causal inference란?
  - 인과관계(causality)를 파악하는 모델링

## 2. 그렇다면 Causal Inference는 언제, 왜 필요할까?

- 인과관계 파악(원인파악, 효과측정)을 위해 제일 좋은 방법은?
  - ⇒ Randomized Control Test (흔히 말하는 A/B 테스트)
    - 모든 변수를 완벽하게 고정하는 대신, 무작위 배정으로 평균적인 효과를 측정할 수 있음.
    - 그런데 A/B 테스트를 할 수 없는 상황이라면 어떡하지?
      - 예를 들어, A/B 테스트를 하는데는 돈&시간이 많이 들고, 데이터 특성 상 테스트를 하기 어려울 수도 있음(윤리적인 문제나 이미 지나간 사건일 경우 등등)
    - ⇒ 데이터를 가지고 인과 관계를 파악하거나 효과를 측정하는 방법이 있을까?
      - 다양한 방법이 있지만. 대표적인 갈래는 크게 두 가지.
        - ⇒ Potential Outcomes Framework와 Causal Graphical Models

# III. Potential Outcomes Framework

## 1. 예시로 알아보는 Potential Outcomes Framework의 정의

- 피노키오는 1년 전 오늘 루나코인을 샀다. 피노키오( $Y_0$ )은 루나를 구입함으로써 어떤 변화를 얻게 되었을까? 얼마나 이득을 보았을까?
  - 1년 전 선택의 그날, 새로운 피노키오( $Y_1$ )은 루나 대신에 적금 통장에 돈을 넣는다.
  - → 새로운 선택을 한 세계에서 1년 간 피노키오( $Y_1$ )가 적금으로 벌어들인 수익을 구하고, 이쪽 세계의 피노키오( $Y_0$ )가 루나 코인으로 벌어들인 수익/손해와 비교한다.
  - → 두 세계에서 바뀐 게 피노키오의 선택 뿐이라면, 이후에 달라지는 모든 결과들은 피노키오의 선택으로 인한 인과적인 영향이라고 볼 수 있다.

- → 그렇다면 피노키오의 선택으로 인한 영향은 간단하게  $Y_0 - Y_1$ 을 계산하면 구할 수 있다.
- ⇒ 하지만 우리는 과거로 돌아가서 새로운 선택을 할 수가 없다.
- 이럴 때 사용할 수 있는 게 **Potential Outcomes Framework**
  - 아래 표에 데이터를 채워 보면,  $Y_1$ (저쪽 세계 피노키오의 수익) 값이 비어있음  
⇒ 그렇다면 빈칸을 예측해서 채워넣으면 됨!

	Y0	Y1		Y0	Y1
A	35	N/A	➡	A	35
B	20	N/A		B	20
C	N/A	50		C	27

- 이처럼 루나 코인에 대한 투자로 인한 평균적인 효과(Average Treatment Effect)를 추정하고 싶다면?

## 2. Potential Outcomes Framework의 대표적인 방법 두 가지

- [방법1] Matching
  - 루나에 투자하지 않은 사람 중에서 피노키오와 가장 유사한 조건의 사람을 찾아서 비교한다.
    - 다양한 조건을 반영하여 최대한 비슷한 사람을 찾고, 유사 피노키오의 1년간 수익을 피노키오와 비교한다.
    - 이런 작업을 모든 사람에 대하여 반복하고, 평균적인 효과를 구한다.
- [방법2] Stratification
  - 유사한 특성을 가진 사람들끼리 그룹을 구성한다.  
→ 각 그룹별로 평균 수익을 구해 ATE를 추정할 수 있다.

## 3. Potential Outcomes Framework의 장점 & 단점


- [장점]
  - Potential Outcomes 방식은 상대적으로 쉽고, 직관적이며, 우리에게 친숙한 도구들을 사용한다.

- 어려운 인과관계 문제를 상대적으로 쉬운 결측치 예측 문제로 바꿔서 해결함;
- 모형보다는 데이터를 중심으로 추론함
- [단점]
  - 데이터만 사용해서 추론하므로 함정에 빠지기 쉽다.
  - ⇒ 따라서 우리는, 우리가 가지고 있는 데이터들이 어떤 방식으로 생성되는지부터 고민해야한다.
  - 데이터의 생성 과정을 그래프를 통해 표현하고, 이를 통해 인과관계를 추론하는 방식이 바로 **Causal Graphical Models** (인과관계 추론의 두번째 방식)

## IV. Causal Graphical Models

### 1. Causal Graphical Models란 무엇인가?

- Causal Graphical Models의 정의
  - 데이터의 생성 과정을 그래프(DAG, Directed Acyclic Graphs, Causal Diagram, Causal Graph)를 통해 표현하고, 이를 통해 인과관계를 추론하는 것
- 이때, 세 개의 변수가 있는 경우에 Causal Diagram에 나타나는 특별한 관계들이 있음



- 이처럼 데이터 생성을 Causal Diagram으로 파악할 수 있으면:

- (1) 변수들의 관계를 바탕으로 인과 관계를 더 명확하게 이해할 수 있음;
- (2) Potential Outcomes 모형에 필요한 조건부 독립 가정들을 그래프를 통해 검증할 수 있음.

## 2. 이렇게 그래프를 그렸으면, 우리는 뭘 구해야 할까?

- 원인과 결과 ( $X \rightarrow Y$ ) 우리는 인과관계 추론을 하는 중이었으므로...!
  - 즉, X에 변화를 주었을 때(개입) Y는 어떻게 변할까?
  - 이것을  $P(Y|do(X))$  라고 한다.
- do(X) operator
  - Causal Graphical Model의 핵심 개념 중 하나
  - do(X) operator의 역할은?
    - X에 영향을 줄 수 있는 모든 부모노드의 효과를 무시하자!
  - $do(X) \neq see(X)$ 
    - see(X):
      - 우리가 관찰할 수 있는  $P(Y|X)$ . 즉, X를 관찰했을 때 Y가 일어날 확률.
      - $P(Y|X)=P(Y|see(X))$
    - do(X):
      - 우리가 X에 변화를 주었을 때(개입) Y는 어떻게 변할까?
      - $P(Y|do(X))$
- 그렇다면 추가적인 실험없이도  $P(Y|X)$ 로  $P(Y|do(X))$ 를 추정할 수 있을까?
  - 가능하다!
  - 특정한 형태의 그래프가 구성되면, 관찰한 데이터를 통해 변화의 영향을 측정할 수 있음.
    - ⇒ 이걸 하는 방법이 Causal Bayesian Network.


# V. Causal Bayesian Network

## 1. Causal Bayesian Network란 무엇인가?


- Causal graph에 Causal Markov Assumption 을 적용해서 변화의 영향을 측정하는 것
- 즉, 관찰한 데이터 & 그래프를 동시에 사용해서 인과관계를 추론하는 것.

## 2. Causal Bayesian Network를 이해해보자.

- Causal Diagram
  - 데이터의 생성 과정을 그래프로 표현한 것.




- Causal Markov Assumption
  - 의미
    - 아래와 같은 causal diagram이 있을 때, “Joint probability를 계산할 때 나에게 영향을 주는(화살표 주는) 변수에만 conditional하다”.



- 특징
  - Causal diagram 하에서 생기는 graphical assumption
    - 즉, causal diagram이 주어졌을 때만 성립하는 가정 (그때만 사용가능함)

- Causal Bayesian Network에서 항상 성립해야 하는(기본적으로 깔고 가는) 가정
  - Causal Markov Assumption이 없을 때와 있을 때, joint probability는 어떻게 달라지나?
- Causal Markov Assumption이 없을 때 (즉, 그래프가 없을 때 일반적으로 적용되는 joint probability):
  - $P(X,Y,Z) = P(X)P(Y,Z|X) = P(X)P(Y|X)P(Z|X,Y)$
- Causal Markov Assumption이 있을 때:
  - 이런 **그래프(causal diagram)**가 주어지면,  
우리는 Causal Markov Assumption을 적용할 수 있음!



- 그렇다면 joint probability는 이렇게 바뀐다!  $P(X,Y,Z) = P(X)P(Y|X)P(Z|Y)$ 
  - WHY? 그래프를 보면,
    - $P(X)$ 는 어떤 변수에도 화살표를 안 받으므로 어떤 변수에도 conditional 하지 않음
    - $P(Y)$ 는 X로부터만 화살표를 받으므로, Y는 X에게만 conditional함
    - $P(Z)$ 는 Y로부터만 화살표를 받으므로, Z는 Y에게만 conditional함
  - 즉, Causal Diagram + Causal Markov Assumption을 이용하면 우리는 joint probability  $P(X,Y,Z)$ 를 이렇게 간소하게 쓸 수 있다고 가정하는 것!

### 3. Why Causal Bayesian Network?

- Bayesian Network 하에서의 joint probability를 바로 구하지 못하는 상황에서,  
→ Causal graph만 주어져 있으면 Causal Markov Assumption에 따라서 이렇게 joint

probability를 conditional probability로 풀어써주는 과정

→ 즉, 우리가 구할 수 있는 marginal probability나 conditional probability로 바꿔줌

## VI. Findings

1. Causal Inference는 발생하지 않은 상황을 상상해서 인과관계를 추론할 수 있으므로 기존의 ML/DL 방법론에 새로운 시각을 제안할 수 있다.
2. 베이지안 방식의 causal inference의 두 가지 대표적인 방법론인 Potential Outcomes Framework와 Causal Graphical Models는 서로 다른 장단점을 가지고 있다.
  - Potential Outcomes Framework
    - 적절한 research design을 통해서 인과추론에 방해가 되는 selection bias를 제거하는 방법
    - [+] 쉽고 직관적이다. 데이터만 사용하므로 상대적으로 친숙하다.
    - [-] 상대적으로 많은 가정을 필요로 한다.
  - Causal Graphical Model
    - 인과관계의 구조를 명시적으로 나타내고, 구조적 topology를 이용해서 인과관계 이외의 Path를 차단해서 인과관계를 추론하는 방법
    - [+] 변수들 사이의 관계를 데이터에 잘 반영할 수 있다.
    - [-] 생소하다. 데이터 생성 그래프까지 필요하므로 모델링이 잘 되어야 좋은 결과를 얻을 수 있다.
3. Causal Bayesian Network에서 기억하면 좋을 개념은?
  - 강의에 나왔던 ~~Bayesian Network Factorization~~
  - Causal Markov Assumption
  - do(X) operator