

Image Segmentation

: 이미지의 모든 픽셀에 대해 클래스를 분류하여 의미있는(semantic)단위로 대상 객체를 분할하는(segmentation) 문제

- 활용 분야: 자율주행, 의료영상 분석, 표면 결함 검출, 위성영상 분석 등 다양한 분야에서 활용
- 방법론
  - Deep Learning을 이용한 방법
  - GMM을 이용한 방법
- Intensity inhomogeneity가 있어도 잘 작동해야한다.



- 뇌 이미지의 경우, 같은 영역임에도 Intensity가 차이가 나는 경우, 보정하면되지만,
- 코끼리 이미지처럼 일반적인 이미지의 경우 Intensity가 균일하지 않음이 오히려 더 도움이 될 수 있다.

GMM-based Image segmentation



- 
- 이미지상의 pixel의 intensity를 data point로 두고 GMM의 EM Algorithm을 통해 n개의 component로 나눈다.
- python



```
from sklearn.mixture import GaussianMixture as GMM
img = cv2.imread("./image.png")
img_ = img.reshape((-1,3))
gmm_model = GMM(n_components = 4, covariance_type= 'tied').fit(img_)
gmm_labels = gmm_model.predict(img_)*255/4
```


- 문제점: component의 개수에 따라 결과가 다르고, 성능 또한 좋다고 평가하기 어렵다.

[논문] Image Segmentation Using Local GMM in a Variational Framework

- GMM + Level Set Method
  - level set method가 bias function의 constraints들이 필요하지 않도록 한다.
- variational framework

Level Set Method


- Active Contour Model
  - 물체 내부와 외부의 energy minimization을 통해서 변형가능한 모델을 이미지에 일치 시키는 방법이다.
    - Energy는 internal energy(curve shape) + external energy(edge)
    - curve를 evolve시키는 방법으로 split과 merge등의 다양한 topological change를 다루는데 한계가 있다.




- object tracking, shape recognition, segmentation등의 CV에서 많이 사용된다.

Level-Set Method

- curve를 시간에 따라 evolve하는 것이 아닌 surface  $\phi$ 라는 function을 정의하고 function을 evolve한다.





- surface, plane, curve로 나뉘는데, surface와 plane이 만나서 생기는 curve를 이용하여 segmentation하는 방법



- 하지만, 워처럼 간단한 이미지에는 효율적이지만, 복잡한 이미지에는 제한적이다.

Proposed Model

- Solving GMM with the Variational Method
  - problem
    - log와 sum 연산은 noncommutative하기 때문에 log-likelihood를 optimizing하는 것이 쉽지 않다
    - $\ln P(X/\mu, \sum) = \sum_{n=1}^N \ln(\sum_{k=1}^K p_{kN}(x/\mu_k, \sum_k))$
  - Solution
    - Add Convex relaxation condition: global optimum를 찾기 쉽게
- Model Assumption
  - Intensity inhomogeneity problem
    - $f(x) = \beta(x)g(x)$ 
      - f: observed data - intensity of the observed image
      - $\beta$ : bias field - nonnegative and smoothly varying(가정2)
      - g: ground truth image - can be segmented by GMM(가정1)
- 비교
  - Classic GMM
    - noise에 취약
    - 밀도가 균일하지 않으면 어려움
    - smoothness constraints가 부족
- 예시



- 결과
  - Robust to noise with non-uniform illumination
  - Formulate a new variational framework for regularized GMM

출처

- <https://nuguziii.github.io/survey/S-002/>
- <http://math0.bnu.edu.cn/~liujun/papers/JMIV2012.pdf>